

Классификация траекторий динамических систем с помощью физически-информированных нейросетей

Терентьев Александр¹, Вадим Стрижев²

¹ФПМИ

МФТИ ²Научный руководитель

Презентация НИР, December 2023

Предсказательная часть сети

За основу классификационного берется физически-информированная лагранжева нейросеть. Ее основная идея состоит в восстановлении функции Лагранжа рассматриваемой системы.

Функция потерь

$$\mathcal{L}(\mathbf{w}) = \frac{1}{m_j} \sum_{i=1}^{m_j} \|\hat{\mathbf{q}}_i^{(j)} - \ddot{\mathbf{q}}_i^{(j)}\|_2^2,$$

Динамика выводится из уравнений Эйлера-Лагранжа

Система для нахождения ускорений

$$(\nabla_{\dot{\mathbf{q}}\dot{\mathbf{q}}} L) \ddot{\mathbf{q}} = [\nabla_{\mathbf{q}} L - (\nabla_{\dot{\mathbf{q}}\mathbf{q}} L) \dot{\mathbf{q}}] .$$

Проблемы прямого подхода

Если решать эту задачу напрямую, то мы встречаемся с проблемой. Решение является неустойчивым, оно не является гладким как того требует физика. А главное для такой функции невозможно проводить никакие дальше исследования. Ее значения скачут и методы сильно зависят от удачности выбора точек. Требуется какая-то модификация

Регуляризация

Поэтому требуется некоторая регуляризация задачи. Вся загвоздка заключается в том, что мы находим значения ускорения из решения СЛАУ

$$H_{\ddot{q}}\ddot{q} = b$$

$$\ddot{q} = (\nabla_{\dot{q}\dot{q}}L)^{-1} [\nabla_q L - (\nabla_{\dot{q}q}L) \dot{q}] .$$

В идеале $(H_{\ddot{q}}) = 1$, т.е. алгоритм должен присвоить всем массам в системе значения 1. Тогда добавим в нашу функцию потерь слагаемое, штрафующее за отклонение собственных значений от 1

$$\mathcal{L}^{mod}(\mathbf{w}) = \frac{1}{m_j} \sum_{i=1}^{m_j} \|\hat{\mathbf{y}}_i^{(j)} - \mathbf{y}_i^{(j)}\|_2^2 + \alpha g(\beta((H_{\ddot{q}}) - 1)),$$

Результаты




Рис.: Отклонения предсказания ускорения для тестовой выборки при разных значениях коэффициента регуляризации

Фазовые портреты

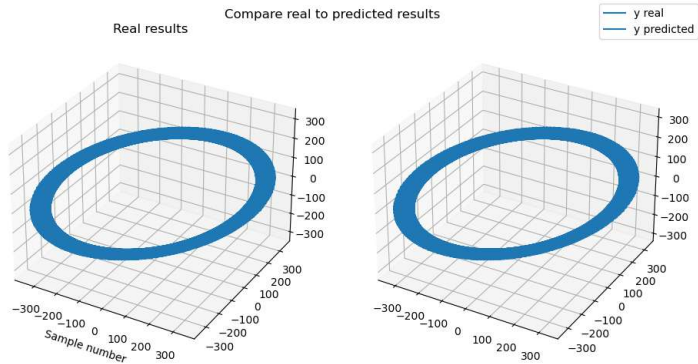


Рис.: Фазовые траектории предсказанных и реальных траекторий

Кривые обучения




Рис.: Зависимость среднеквадратичного отклонения + ограничений от шага обучения

Теоретические результаты о эквивалентности нахождения минимума невязки и отклонения ускорений

Lemma

Если лагранжианы заданы на компакте, то существуют неотрицательные числа a, b такие, что $\det H \geq a$, а собственные значения матрицы H не меньше b

$$\|L\|_L = \|(A(L), H(L))\|_2$$

Lemma

$\|L\|_L = 0 \Leftrightarrow$ п.в. $\delta\ddot{q} = 0$, где $\delta L, \delta\ddot{q}$ являются вариациями лагранжиана и ускорения.

Теоретические результаты для выбора нормы

$$\|(A(L).H(L))\|_2 = \sqrt{\int |A(L)(\mathbf{q}, \dot{\mathbf{q}})|^2 + \|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2 d\Omega} \approx$$

$$\sum_{i_1=1, \dots, i_n=1}^{N, \dots, N} |A(L)(\mathbf{q}, \dot{\mathbf{q}})|^2 + \|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2 \frac{\Delta X_1 \cdot \dots \cdot X_n}{N \cdot \dots \cdot N} =$$

$$C \cdot \sum_{i_1=1, \dots, i_n=1}^{N, \dots, N} \frac{A(L)(\mathbf{q}, \dot{\mathbf{q}})^2 + \|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2}{N \cdot \dots \cdot N} =$$

$$C \cdot \overline{|A(L)(\mathbf{q}, \dot{\mathbf{q}})|^2 + \|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2}$$

Теоретические результаты для выбора нормы

Theorem

Пусть есть конечное семейство непересекающихся замкнутых выпуклых множеств \mathcal{A} в нормированном пространстве \mathbb{L} , тогда существует $\epsilon > 0$, что для любого преобразования пространства ϕ такое, что $\|\phi(A_i) - A_i\| < \epsilon$ множества из семейства $\phi\mathcal{A}$ попарно сильно отделимы.

Вычислительный эксперимент

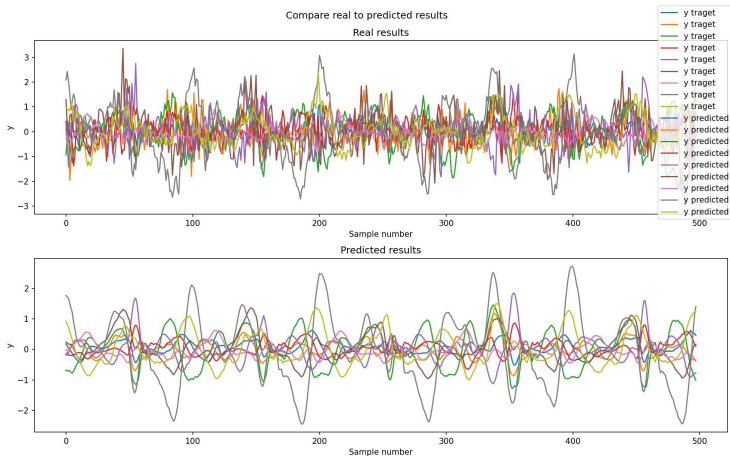


Рис.: Временной ряд предсказанного ускорения в зависимости от времени для траектории

Идея классификатора

Аппроксимация нормы

$$|A(L)(\mathbf{q}, \dot{\mathbf{q}})|^2 + \|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2$$

$$\|H(L)(\mathbf{q}, \dot{\mathbf{q}})\|_2^2 \approx \text{const}$$

Если мы перейдем от признаков $(\mathbf{q}, \dot{\mathbf{q}})$ к признаковому пространству $A(L)(\mathbf{q}, \dot{\mathbf{q}})$, то мы перейдем к пространству с евклидовой нормой. Осталось зафиксировать точки в которых мы сэмплируем значения функции. Используя метод Монте-Карло Мы получаем набор $S = \{s_i\}$ из $N = 2000$ точек $(\mathbf{q}, \dot{\mathbf{q}})$ равномерно распределенных на кубе $-a \leq x_i \leq a$. Кол-во точек подбирается так, чтобы соответствующая норма не сильно менялось при увеличении числа точек.

Вычислительный эксперимент




Рис.: Распределения данных в 2D

Вычислительный эксперимент




Рис.: Распределения данных в 3D

Вычислительный эксперимент




Рис.: Точность классификации выбранных метод в зависимости от количества главных компонент